





Klassifikationsmodelle am Limit


Die Attacke lebenswichtiger medizinischer KI-Systeme

In dieser Arbeit untersuchen wir den Einsatz von Adversarial Training zum Schutz medizinischer Klassifikationsmodelle vor
Universal Adversarial Attacks (UAAs)



Adversarial Attack

Adversarial Attacks sind ein Phänomen im Bereich des Deep Learning, das in den letzten Jahren zunehmend an Bedeutung gewonnen hat. Bei diesen Angriffen auf Bildklassifikationsmodelle werden die Eingabewerte durch eine minimale Veränderung modifiziert, die vom menschlichen Auge nicht mehr wahrnehmbar ist. Diese Angriffe beziehen sich auf Manipulationen von Eingabedaten, die darauf abzielen, neuronale Netzwerke zu täuschen und falsche Vorhersagen zu erzwingen. Sie werfen wichtige Fragen zur Robustheit und Sicherheit von Deep Learning Modellen auf und haben weitreichende Implikationen für deren praktische Anwendungen Goodfellow et al. (2015).



Adversarial Training

Adversarial Training ist derzeit die einzige wirksame Verteidigung gegen Adversarial Attacks. Viele andere Mechanismen wurden getestet, aber keine Abwehrstrategien wurden umfassend analysiert und als wirksam befunden. Adversarial Training generiert Perturbationen und trainiert das Modell iterativ weiter, um es robust zu machen. Die Perturbationen müssen infolgedessen grösser werden, um das Modell zu täuschen.

Unsere Arbeit zeigte, dass Adversarial Training keinen wirksamen Schutz gegen UAAs bietet. Weitere Forschung in diesem Bereich ist wichtig, da KI-Systeme immer mehr Anwendung finden und ihnen vermehrt vertraut wird.